

# ATIVIDADE PRÁTICA AVALIATIVA FINAL - PROJETO INTEGRADOR I

## Construção de um Pipeline de Dados para um Problema de Classificação

### Objetivo

O objetivo desta atividade é permitir que cada estudante desenvolva seu próprio projeto de análise de dados utilizando um conjunto de dados de seu interesse, aplicando os conceitos estudados ao longo da disciplina.

Durante as aulas, foi apresentado um exemplo completo utilizando o dataset de Potabilidade da Água, demonstrando as principais etapas de um pipeline de dados. Agora, cada estudante deverá construir uma análise própria, utilizando um conjunto de dados diferente, selecionado de acordo com seus interesses acadêmicos ou profissionais.

### Descrição da Atividade

Cada estudante deverá escolher um dataset disponível no Kaggle que atenda aos seguintes critérios:

- Estar no formato CSV;
- Possuir uma variável alvo (target);
- Ser um problema de classificação;
- Possuir quantidade suficiente de registros para realização das análises exploratórias.

Após a escolha do dataset, o estudante deverá desenvolver um notebook no Google Colab contendo um pipeline semelhante ao apresentado em aula, porém com identidade própria, demonstrando suas interpretações, análises e conclusões.

O notebook poderá seguir a estrutura estudada em sala, mas deverá apresentar a marca do estudante, com comentários, observações e justificativas próprias para cada etapa realizada.

### Etapas Mínimas Esperadas

#### 1. Apresentação do Dataset

- Nome do dataset;
- Link para o Kaggle;
- Contextualização do problema;
- Descrição das variáveis.

#### 2. Carregamento dos Dados

- Importação do arquivo CSV;
- Visualização inicial dos registros;
- Verificação dos tipos de dados.

#### 3. Análise Descritiva

- Estatísticas básicas;
- Frequência das classes;
- Análise inicial das variáveis.

#### 4. Tratamento dos Dados

- Identificação de valores ausentes;
- Tratamento ou imputação dos dados;
- Justificativa das decisões adotadas.

## 5. Análise Exploratória

Utilizar visualizações adequadas, tais como:

- Histogramas;
- Boxplots;
- Scatterplots;
- Matriz de correlação.

**\* Cada gráfico deverá possuir uma breve interpretação dos resultados observados.**

## 6. Preparação dos Dados

- Separação entre atributos e variável alvo;
- Divisão entre treino e teste;
- Aplicação das transformações necessárias.

## 7. Construção de um Modelo de Classificação

- Decision Tree;
- Random Forest;
- KNN;
- Gradient Boosting;
- Redes Neurais;
- Outros algoritmos de classificação.

**\* O estudante poderá utilizar qualquer algoritmo de classificação estudado ou pesquisado, como:**

## 8. Avaliação do Modelo

**Apresentar pelo menos:**

- Acurácia;
- Matriz de Confusão;
- Classification Report.

## 9. Conclusão

Apresentar uma análise crítica dos resultados obtidos, discutindo:

- Dificuldades encontradas;
- Qualidade dos dados;
- Desempenho do modelo;
- Possíveis melhorias futuras.

## Entrega

A entrega deverá ser realizada por meio do envio do notebook (.ipynb) no ambiente virtual da disciplina. Caso utilize datasets complementares, estes também deverão ser anexados.

## Prazo

Data limite para entrega: 05 de julho de 2026

## **Observação Importante**

O objetivo desta atividade não é reproduzir exatamente o notebook apresentado em aula.

Espera-se que cada estudante desenvolva sua própria solução, demonstrando autonomia, capacidade de investigação e aplicação dos conceitos estudados na disciplina.

Mais importante do que obter uma alta taxa de acerto é demonstrar compreensão das etapas do pipeline de dados e justificar as decisões tomadas ao longo do projeto.

Lembre-se: em Ciência de Dados, documentar o processo é tão importante quanto apresentar os resultados.

"Escolha um tema que desperte sua curiosidade. Esportes, saúde, educação, finanças, agricultura, tecnologia, jogos ou qualquer outra área de interesse. O importante é que, ao final da disciplina, você tenha construído um projeto que represente sua identidade como futuro profissional de Inteligência Artificial e Ciência de Dados."